

Análisis exploratorio de datos de reseñas de vinos

Trabajo Práctico 2, Seminario de Programación para Ciencia de Datos

Lucas Llano

22 de septiembre de 2026

Conjunto de datos: winemag-data-130k-v2 (WineEnthusiast)

Índice

1. Introducción	3
2. Descripción del conjunto de datos	3
3. Carga e integridad del archivo	4
3.1. Delimitador de campos incorrecto	5
3.2. Reseñas repartidas en varias filas	5
3.3. Codificación de caracteres.....	5
3.4. Verificación de la carga.....	6
4. Análisis exploratorio	6
4.1. Estructura y valores repetidos	6
4.2. Resumen estadístico de las variables numéricas	7
4.3. Resumen estadístico de las variables categóricas.....	7
4.4. Distribución de los puntajes	9
4.5. Distribución de los precios	10
5. Tratamiento de datos faltantes.....	11
5.1. Cuantificación y co-ocurrencia	11
5.2. El faltante estructural como información	12
5.3. Diagnóstico del mecanismo de ausencia del precio	13
5.4. Estrategias disponibles y cuándo sirve cada una.....	14
5.5. Selección de la estrategia mediante validación	15
5.6. Decisiones adoptadas y prevención de circularidad.....	16
6. Análisis de datos atípicos	16
6.1. Comparación de criterios de detección	16
6.2. Naturaleza y causa: la extremidad estadística no identifica errores	17
6.3. Impacto sobre las conclusiones	18
6.4. Tratamiento adoptado.....	19
7. Análisis comparativo entre variables	19

7.1. Relación entre precio y puntaje	19
7.2. Comparación entre países.....	20
7.3. El año de cosecha como variable derivada.....	21
7.4. Extensión de la nota de cata	22
7.5. Efecto del catador y confusión por variable omitida.....	23
8. Conclusiones	24
9. Referencias	25
Anexo. Estructura del script	26

1. Introducción

Este informe documenta un análisis exploratorio sobre 129.971 reseñas de vinos publicadas por WineEnthusiast. Busca entender cómo están armados los datos, encontrar y corregir sus defectos, y sacar conclusiones sostenibles sobre las características, los precios y las calificaciones de los vinos reseñados.

El trabajo avanza en seis etapas, que se corresponden una a una con las secciones del script entregado: carga e integridad del archivo, perfilado de la estructura, análisis descriptivo y visual, tratamiento de datos faltantes, análisis de datos atípicos y comparación entre variables.

Conviene enunciar desde el principio la idea que ordena todo lo que sigue: que un programa no lance un error no prueba que los datos estén bien. El archivo entregado se carga sin quejarse y aun así llega con tres formas distintas de corrupción. Encontrarlas exigió fijar criterios de verificación *antes* de cargar, y no después de mirar el resultado.

Sobre el lenguaje: la consigna abierta menciona R y Python, mientras que el Formato entregable pide un único script y admite explícitamente cualquiera de los dos según la elección del autor. El análisis se hizo enteramente en Python, que es donde están las herramientas usadas acá para reparar el archivo, validar la imputación y medir el efecto de los valores atípicos. El script se entrega en un solo archivo, como pide ese apartado.

2. Descripción del conjunto de datos

El conjunto reúne reseñas de vinos con su origen geográfico, la variedad de uva, la bodega productora, el precio de una botella, el puntaje asignado y la nota de cata que escribió el catador. Cada fila es una reseña.

El enunciado describe el archivo como 130.000 reseñas en 10 columnas. Contra el archivo real son 129.971 reseñas y 13 columnas. La diferencia en las columnas no es un redondeo: el propio enunciado enumera trece nombres de campo en su descripción detallada, así que se contradice dentro de la misma página.

El criterio que se adopta es que los datos son la única evidencia de lo que el archivo contiene, y el enunciado una afirmación que hay que verificar. Vale aclarar que de esa discrepancia no se sigue que el archivo esté bien, sino sólo que al menos una de las dos fuentes está mal. Como muestra la sección 3, acá fallan las dos.

Tabla 1. Variables del conjunto de datos y su naturaleza analítica.

Variable	Tipo	Descripción
country	Categórica	País de origen del vino (43 valores)
description	Texto libre	Nota de cata redactada por el catador
designation	Categórica	Viñedo específico dentro de la bodega
points	Numérica discreta	Puntaje de 80 a 100 asignado por WineEnthusiast
price	Numérica continua	Precio de una botella en dólares
province	Categórica	Provincia o estado de origen (425 valores)
region_1	Categórica	Área vinícola dentro de la provincia
region_2	Categórica	Sub-área vinícola (sólo Estados Unidos)
taster_name	Categórica	Catador que realizó la reseña (19 valores)
taster_twitter_handle	Categórica	Usuario de Twitter del catador
title	Texto libre	Título de la reseña; incluye el año de cosecha
variety	Categórica	Variedad de uva (707 valores)
winery	Categórica	Bodega productora (16.757 valores)

Hay una segunda contradicción en el enunciado, esta vez informativa y no errónea. Al describir *points* dice que la escala va de 1 a 100 y, en la misma línea, que sólo se publican reseñas con 80 o más. La variable observada está entonces **censurada**: no describe la calidad de los vinos evaluados sino la de los que pasaron el umbral de publicación. Esa característica condiciona la lectura de toda la sección 6.

3. Carga e integridad del archivo

La consigna indica cargar winemag-data-130k-v2.csv. Lo que se entregó es un archivo con extensión .xlsx de 21 MB, y no es una hoja de cálculo con datos tabulados: es ese mismo

CSV después de una importación mal configurada en Excel. La inspección encontró tres defectos de distinto origen.

3.1. Delimitador de campos incorrecto

Abriendo el archivo de la forma obvia, las trece columnas esperadas aparecen como cinco: una con la línea CSV completa y cuatro con nombre genérico, casi siempre vacías. Los valores no nulos de esas cuatro caen en cascada, 2.956, 159, 12 y 1, que es el patrón típico de un texto partido por un separador que la mayoría de las líneas no contiene.

Mirando una fila afectada, el corte cae en mitad de una oración: la descripción termina en «passion fruit and kiwi» y la celda siguiente arranca en «a sprinkling of graham cracker». El signo que unía las dos cláusulas ya no está, porque un analizador sintáctico se come su propio delimitador.

El carácter se identificó por dos vías que llegaron a lo mismo. La gramatical: el punto y coma es el único signo que une dos cláusulas independientes con minúscula a continuación. Y la empírica, que es la más fuerte: si Excel usó un carácter como delimitador, lo borró de todo el archivo, así que el delimitador tiene que ser el signo de puntuación que falta por completo en el texto. Contando sobre las 129.975 líneas aparecen decenas de miles de comas y de puntos, y cero punto y coma en 130.000 reseñas escritas por críticos profesionales. La reversión consiste en volver a unir las celdas no vacías de cada fila con ese carácter en el medio.

3.2. Reseñas repartidas en varias filas

Cuatro descripciones traían saltos de línea adentro del texto y quedaron distribuidas en más de una fila de la hoja. Se las detecta porque toda línea de datos sana empieza con el índice numérico seguido de coma; una línea que no sigue ese patrón es la continuación de la anterior y hay que pegarla. Sin esa corrección el conjunto habría quedado con cuatro registros basura y cuatro descripciones cortadas.

3.3. Codificación de caracteres

El texto venía con *mojibake*: «Gewürztraminer» aparecía como «GewÃ¼rztraminer» y «Albariño» como «AlbariÃ±o». Pasa cuando una secuencia de bytes UTF-8 se lee byte a byte con la codificación cp1252. La vuelta atrás es exacta: se codifica el texto en cp1252 para recuperar los bytes originales y se decodifica como UTF-8, que es lo que siempre fueron. El procedimiento reparó 106.479 de las 106.611 celdas afectadas.

Tres celdas habían pasado dos veces por la conversión equivocada y tenían mojibake sobre mojibake: «crème» figuraba como «crÃfÂ¨me», y una sola vuelta la dejaba en «crÃ¨me», todavía rota. La reparación se repite hasta que el texto deja de cambiar. Las 132 celdas que quedan sin arreglar son comillas tipográficas cuya secuencia de bytes usa posiciones que cp1252 no define.

La función no puede dañar texto que ya está bien. Una cadena ASCII atraviesa la conversión sin cambios, y una con acentos legítimos falla al decodificar y vuelve intacta, así que el ciclo se detiene en el valor correcto.

3.4. Verificación de la carga

El criterio de éxito se fijó antes de ejecutar la carga, para no razonar sobre un resultado que ya se tiene a la vista. Como el encabezado declara trece nombres de columna precedidos por un campo de índice sin nombre, toda línea reconstruida tiene que dar exactamente catorce campos al analizarse como CSV. La condición se cumple sin excepciones en las 129.972 líneas, contando el encabezado. El script la conserva como aserción, así que falla de forma visible si el archivo de origen cambia.

La carga devuelve 129.971 reseñas por 13 columnas, con points entero y price decimal. El script acepta además el CSV original: elige qué hacer según la extensión del archivo y los dos caminos llegan al mismo DataFrame, cosa que se verificó comparándolos celda por celda.

4. Análisis exploratorio

4.1. Estructura y valores repetidos

El perfilado inicial separa las variables en dos grupos bien distintos. Están las categóricas de baja cardinalidad, aptas para análisis de frecuencias: country con 43 valores, taster_name con 19, region_2 con 17. Y están los campos cuya cardinalidad se acerca al total, que son texto libre o identificadores y no admiten ese tratamiento: description llega al 92,3% de valores únicos y title al 91,4%.

Que ninguno de esos dos campos llegue al 100% lleva a un hallazgo importante: hay 9.983 pares de filas idénticas en las trece columnas. Comparar sólo por descripción o sólo por título da el mismo número, lo que confirma que son filas repetidas enteras y no reseñas distintas que compartan texto. El origen más probable es la extracción del sitio web.

Se eliminaron conservando la primera aparición de cada una. La decisión no es de prolijidad sino de validez: con el 7,7% de las filas duplicadas, esas reseñas pesarían el doble en toda media, frecuencia, ranking y correlación posterior, y sesgarían los resultados hacia lo que la extracción repitió. El conjunto de trabajo queda en 119.988 reseñas.

4.2. Resumen estadístico de las variables numéricas

Tabla 2. Resumen estadístico de las variables numéricas.

Estadístico	points	price
Media	88,45	35,36
Mediana	88,00	25,00
Desvío estándar	3,04	41,02
Mínimo	80,00	4,00
Máximo	100,00	3.300,00
Rango intercuartílico	5,00	25,00
Asimetría	0,05	18,00
Curtosis	-0,30	829,52
Coefficiente de variación	0,03	1,16

Las dos variables piden tratamientos opuestos. *points* es casi simétrica: con asimetría de 0,05 y media que coincide con la mediana, se la puede resumir con media y desvío estándar. *price* tiene asimetría de 18,00 y curtosis de 829,52, valores muy lejos del 0 que corresponde a una normal. Su media supera a la mediana en un 41% y su máximo es 132 veces la mediana.

De ahí sale una regla que se aplica en el resto del informe: para *price* se usan mediana y rango intercuartílico en lugar de media y desvío, y escala logarítmica en todo gráfico.

4.3. Resumen estadístico de las variables categóricas

Las medidas que sirven para una variable numérica no tienen sentido acá: no existe el promedio de un país ni el desvío de una variedad. El equivalente para una categórica son la

moda, cuánto pesa esa moda sobre el total y alguna medida de qué tan repartida está la masa entre categorías.

Para lo último se usa la entropía de Shannon dividida por su máximo posible. Vale 0 cuando todas las reseñas caen en una sola categoría y 1 cuando se reparten en partes iguales, así que permite comparar la concentración de variables que tienen muy distinta cantidad de categorías. Se excluye el texto libre, porque con más del 90% de valores únicos su moda aparece dos o tres veces y no informa nada.

Tabla 3. Resumen estadístico de las variables categóricas, sobre el conjunto sin duplicados.

Variable	Categorías	Moda	Moda %	Top 10 %	Entropía
country	43	US	42,1	96,0	0,510
province	425	California	28,0	61,5	0,577
region_1	1.229	Napa Valley	4,2	24,6	0,769
region_2	17	Central Coast	21,9	92,3	0,802
variety	707	Pinot Noir	10,2	55,0	0,598
winery	16.757	Wines & Winemakers	0,2	1,5	0,925
designation	37.979	Reserve	2,2	8,6	0,910
taster_name	19	Roger Voss	24,8	92,2	0,797




Figura 1. Quince categorías más frecuentes de las cuatro variables categóricas principales.

La tabla y la figura cuentan la misma historia por dos caminos. La concentración geográfica es fuerte: Estados Unidos aporta el 42,1% de las reseñas, los tres primeros países reúnen el 74,0% y las diez primeras categorías cubren el 96,0%. En province se repite el patrón, con California sola en el 28,0%.

La entropía separa dos comportamientos que el gráfico deja ver pero no cuantifica. country queda en 0,510, bien por debajo del reparto uniforme, y winery en 0,925: con 16.757 bodegas distintas, las quince más frecuentes apenas suman el 2,0% del total. Esa cola larga significa que ninguna bodega individual es representativa, y desaconseja cualquier comparación a ese nivel de agregación. La variable designation muestra lo mismo, con 0,910.

El caso de region_2 merece una nota. Tiene sólo 17 categorías y una entropía alta, 0,802, pero eso se explica porque la columna existe únicamente para los vinos estadounidenses, como detalla la sección 5.2. Dentro de ese subconjunto el reparto es parejo; fuera, la variable no aplica.

4.4. Distribución de los puntajes




Figura 2. Distribución de puntajes. La barrera vertical en 80 responde al umbral de publicación, no a la ausencia de vinos por debajo de ese valor.

La distribución es aproximadamente simétrica y unimodal alrededor de 88 puntos, pero se corta de golpe en 80 y no tiene cola izquierda. Ese corte no dice nada sobre los vinos: es el criterio editorial de WineEnthusiast, que no publica reseñas por debajo de ese puntaje.

La consecuencia para la interpretación es grande. Decir que «el vino promedio obtiene 88 puntos» es un artefacto del sesgo de selección y no un hallazgo sobre la calidad de los vinos. La variable describe a los vinos publicados, que son una muestra deliberadamente no representativa de los vinos evaluados.

4.5. Distribución de los precios




Figura 3. La misma variable bajo dos escalas. La asimetría cae de 18,00 a 0,60 al aplicar el logaritmo.

El panel izquierdo muestra por qué la escala lineal no sirve para esta variable: la asimetría aplasta el 99% de las observaciones contra el eje vertical y deja el resto del gráfico vacío. El panel derecho tiene los mismos datos en escala logarítmica, donde la distribución se vuelve aproximadamente simétrica, con asimetría de 0,60.

El precio se comporta entonces como una variable **log-normal**. Usar el logaritmo no es un recurso estético: es reconocer la escala en la que la variable ya es simétrica, y de eso dependen las conclusiones de la sección 6.

5. Tratamiento de datos faltantes

5.1. Cuantificación y co-ocurrencia




Figura 4. Faltantes por columna y probabilidad condicional de co-ocurrencia entre pares de columnas.

Tabla 4. Valores faltantes por columna y mecanismo diagnosticado.

Variable	Faltantes	%	Mecanismo
region_2	79.460	61,1	Estructural
designation	37.465	28,8	Estructural
taster_twitter_handle	31.213	24,0	Dependiente
taster_name	26.244	20,2	No informado
region_1	21.247	16,3	Estructural
price	8.996	6,9	MAR
province	63	0,05	Desconocido
country	63	0,05	Desconocido
variety	1	0,00	Desconocido

El panel derecho de la Figura 4 distingue faltantes estructurales de aleatorios con probabilidades condicionales, y da dos resultados firmes. La probabilidad de que falte *taster_twitter_handle* dado que falta *taster_name* es exactamente 1,00: la segunda columna es una función de la primera y su ausencia no agrega información. Y la probabilidad de que falte *region_2* dado que falta *price* llega a 0,98, lo que indica que los dos faltantes comparten una causa: el origen geográfico.

5.2. El faltante estructural como información

Lo más habitual frente a una columna con 61% de valores ausentes es descartarla, y acá sería un error grave. *region_2* está presente en el 92,7% de los vinos estadounidenses y en cero reseñas del resto del mundo. No es una columna incompleta: es una columna completa para el subconjunto donde tiene sentido, ya que designa sub-apelaciones propias del sistema vitivinícola de Estados Unidos.

Lo mismo vale para *designation* y *region_1*. No todo vino viene de un viñedo designado ni de un área vinícola delimitada. En estos casos el valor ausente no es un dato perdido sino la

categoría «no aplica», y reemplazarlo por una etiqueta explícita conserva esa información, mientras que imputarlo inventaría un dato que nunca existió.

5.3. Diagnóstico del mecanismo de ausencia del precio

El precio es la única variable cuyo faltante es un dato realmente perdido, así que es la única candidata a imputación. Saber por qué falta es lo que decide qué estrategia corresponde.

- **MCAR** (ausencia completamente aleatoria): no se relaciona con ninguna variable. Cualquier imputación razonable sirve y eliminar las filas afectadas no introduce sesgo.
- **MAR** (ausencia aleatoria condicionada): depende de variables que sí se observan. Imputar con un valor global sesga el resultado y hay que condicionar.
- **MNAR** (ausencia no aleatoria): depende del propio valor faltante y no se puede corregir sólo con los datos disponibles.

Tabla 5. Proporción de precios ausentes por país, en países con al menos 1.000 reseñas.

País	Reseñas	% sin precio
Francia	20.353	20,0
Austria	3.034	16,4
Portugal	5.256	14,3
Italia	17.940	13,6
Sudáfrica	1.301	8,1
Nueva Zelanda	1.278	3,0
Argentina	3.544	1,2
España	6.116	1,1
Estados Unidos	50.457	0,4

Francia tiene cincuenta veces más precios ausentes que Estados Unidos, y la proporción además crece con el puntaje, del 0,5% entre los vinos de 80 puntos al 15,2% entre los de 99. La ausencia depende de variables observadas, así que el mecanismo es **MAR**. Lo que se sigue de

eso es directo: imputar con la mediana general pondría precios del mercado estadounidense, más barato, en vinos franceses e italianos.

5.4. Estrategias disponibles y cuándo sirve cada una

Antes de elegir conviene repasar el abanico de opciones, porque cada una asume cosas distintas sobre por qué falta el dato.

- **Eliminación por lista.** Se descarta toda fila con algún valor ausente. Es simple y deja un conjunto completo, pero sólo es inocua bajo MCAR: si la ausencia se concentra en ciertos grupos, como pasa acá con Francia e Italia, elimina justamente a esos grupos y sesga la muestra. Sobre este conjunto habría costado el 6,9% de las reseñas, con Francia perdiendo una de cada cinco.
- **Eliminación por pares.** Cada cálculo usa las filas que tengan los datos que ese cálculo necesita. Aprovecha más información que la anterior, pero deja estadísticos calculados sobre muestras distintas, lo que complica compararlos entre sí.
- **Imputación por media, mediana o moda.** Se reemplaza el faltante por un único valor central de toda la columna, la moda en el caso de las categóricas. Es la opción más difundida y la que más daño silencioso hace: concentra masa en un punto, achica artificialmente la varianza y debilita las correlaciones con el resto de las variables.
- **Imputación condicional o por grupos.** Misma idea, pero el valor central se calcula dentro del grupo al que pertenece cada fila. Corrige el problema principal de la anterior cuando el mecanismo es MAR, porque usa justamente las variables de las que depende la ausencia. Es la estrategia que se adoptó acá.
- **Hot-deck.** El valor se copia de otra fila parecida del mismo conjunto, elegida al azar entre las candidatas. Preserva mejor la forma de la distribución que un valor central, a cambio de introducir azar en el resultado.
- **Imputación por regresión.** Se ajusta un modelo que predice la variable faltante a partir de las demás. Aprovecha más estructura, pero los valores imputados caen exactamente sobre la recta ajustada, lo que hace que los datos parezcan más ordenados de lo que son.
- **Vecinos más cercanos (KNN).** El valor sale del promedio de las k filas más parecidas según las demás variables. Funciona bien con relaciones no lineales, aunque exige definir una distancia sobre variables de tipos mezclados y es costoso en conjuntos grandes.

- **Imputación múltiple.** Se generan varios conjuntos completos distintos, se analiza cada uno y se combinan los resultados. Es lo más riguroso cuando interesa cuantificar la incertidumbre que agrega la imputación, y por eso se usa en trabajo inferencial. Para un análisis exploratorio descriptivo como este agrega complejidad sin cambiar las conclusiones.

Las tres primeras quedan descartadas por el diagnóstico de la sección anterior: un mecanismo MAR castiga tanto a la eliminación como a la imputación global. La elección entre las restantes no se hizo por preferencia teórica sino midiendo, que es lo que trata la sección siguiente.

5.5. Selección de la estrategia mediante validación

Se ocultó una muestra de precios que sí se conocen, se imputó con cada estrategia candidata y se midió el error contra el valor real, que en esas filas está disponible.

El ocultamiento copió el patrón MAR observado, escondiendo proporcionalmente más en los países que de verdad tienen más ausencias, en lugar de sortear filas al azar. Evaluar contra un patrón MCAR artificial habría favorecido de más a los métodos globales, que son justo los que fallan cuando la ausencia se concentra.

Tabla 6. Error de cada estrategia de imputación sobre precios ocultados deliberadamente.

Estrategia	MAE	Error mediano	MAPE
Media global	\$24,35	\$17,44	61,1%
Mediana global	\$21,96	\$10,00	47,1%
Mediana por país	\$21,66	\$10,00	44,4%
Mediana por variedad	\$19,57	\$9,00	35,9%
Mediana por país y variedad	\$18,73	\$8,00	33,3%
Mediana por país, variedad y puntaje	\$14,92	\$6,00	25,0%

La estrategia adoptada baja el error absoluto medio de \$21,96 a \$14,92 y el error porcentual mediano del 47% al 25% frente a la mediana global. Sumar el puntaje al agrupador es lo que más aporta, algo que coincide con la relación exponencial entre precio y puntaje que documenta la sección 7.1. Se usan medianas y no medias porque dentro de cada grupo la media sigue inflada por unas pocas botellas muy caras. Una cascada de respaldos, del agrupamiento más específico al más general, garantiza que no queden nulos.

5.6. Decisiones adoptadas y prevención de circularidad

No se eliminó ninguna fila. Las 63 reseñas sin país y la única sin variedad conservan puntaje, precio y descripción válidos: descartarlas habría perdido esa información a cambio de nada, mientras que etiquetarlas como «Desconocido» deja la ignorancia declarada y visible en cualquier tabla de frecuencias.

Cada precio imputado quedó señalado con una columna auxiliar. La precaución hace falta porque la imputación usa *points* como variable de agrupamiento: estudiar la relación entre precio y puntaje sobre valores generados a partir del puntaje reforzaría esa misma relación de manera artificial. Es un caso de **circularidad**, y la columna auxiliar permite dejar afuera los valores sintéticos de todo análisis donde comprometan la conclusión. Los análisis de las secciones 6 y 7 se hicieron sólo sobre precios observados.

6. Análisis de datos atípicos

6.1. Comparación de criterios de detección

Tabla 7. Proporción de observaciones señaladas como atípicas según el criterio empleado.

Criterio	% en price	% en points
Rango intercuartílico clásico	6,16	0,04
Puntuación z, $ z > 3$	0,97	0,10
z modificado sobre la MAD, $ z > 3,5$	6,41	0,04
Rango intercuartílico sobre log(x)	0,97	0,02

Los criterios discrepan por un factor de seis sobre la misma variable, y esa discrepancia ya es un hallazgo. El rango intercuartílico clásico supone una distribución más o menos simétrica; aplicado a una variable con asimetría 18 termina marcando el 6,16% de las observaciones, que no son casos excepcionales sino la cola natural de la distribución.

La puntuación z falla de otra manera: usa media y desvío estándar, que son los estadísticos que los valores extremos distorsionan, así que el criterio se muerde la cola y detecta de menos. El z modificado arregla eso cambiándolos por mediana y desviación absoluta mediana, que los extremos no arrastran. El rango intercuartílico sobre el logaritmo es el más defendible para esta variable, porque aplica el criterio en la escala donde de verdad es simétrica.




Figura 5. Umbrales de los dos criterios más discrepantes y distribución del cociente contra el grupo de pares.

6.2. Naturaleza y causa: la extremidad estadística no identifica errores

Los criterios anteriores contestan «¿es un valor extremo?». La consigna pide contestar otra cosa: «¿es un error?». Y eso no se resuelve mirando la distribución global.

Château Pétrus a 2.500 dólares y Château Margaux a 1.900 son extremos y correctos, porque esos vinos se venden efectivamente a esos precios. Un Médoc corriente a 3.300 dólares es igual de extremo y no puede serlo. Los dos superan cualquier umbral estadístico y piden tratamientos opuestos.

Para separarlos se comparó cada precio con la mediana de su **grupo de pares**, o sea los vinos de la misma provincia y el mismo puntaje. Un vino caro entre vinos caros da un cociente cercano a 1; un vino caro entre vinos baratos se delata. La distribución de cocientes concentra su masa alrededor de 1 y pone el percentil 99,9 en 7,3, así que un umbral de 10 queda fuera del alcance de la variación normal del mercado.

Tabla 8. Precios más alejados de su grupo de pares.

Vino	Puntos	Precio	Pares	Cociente
Château les Ormes Sorbet 2013 Médoc	88	\$3.300	\$20	165,0
Blair 2013 Roger Rose Chardonnay	91	\$2.013	\$40	50,3
Domaine Pellé 2014 Morogues Rosé	87	\$800	\$20	40,0
Burmester 1963 Colheita Port	87	\$790	\$25	31,6
Henschke 2009 Hill of Grace Shiraz	91	\$780	\$30	26,0
Château Pétrus 2014 Pomerol	96	\$2.500	\$175	14,3

El procedimiento encontró dos errores de carga con evidencia sólida:

- El Blair 2013 Roger Rose Chardonnay figura a \$2.013, cifra que coincide exactamente con el año de cosecha que lleva el título. La misma bodega vende sus otros siete vinos entre 22 y 75 dólares, y la cosecha 2012 de este mismo vino aparece a 28. Todo apunta a que el año se cargó en el campo de precio.
- El Château les Ormes Sorbet 2013 Médoc figura a \$3.300 y es el único vino de Burdeos con 88 puntos que pasa los 50 dólares, sobre 519 casos cuya mediana es 20. El precio es 165 veces el de su grupo de pares.

En cambio el Oporto Burmester de 1963 a 790 dólares y el Château Pétrus a 2.500 son valores legítimos: un cociente alto en vinos de guarda excepcional o de denominaciones de prestigio refleja el mercado real y no un error de registro.

6.3. Impacto sobre las conclusiones

Tabla 9. Correlación entre precio y puntaje bajo distintos tratamientos de los atípicos.

Escenario	n	Pearson	Spearman
Precio crudo, con atípicos	111.593	0,417	0,612
Precio crudo, sin atípicos por IQR	104.724	0,544	0,572
Logaritmo del precio, con atípicos	111.593	0,618	0,612

Pearson mide asociación lineal, así que sobre una variable con asimetría 18 subestima la relación real y da 0,417. Spearman trabaja sobre rangos, no se inmuta ante transformaciones monótonas de escala y por eso casi no se mueve entre escenarios: sirve como referencia robusta contra la cual comparar.

Lo que muestra la tabla es que eliminar atípicos y transformar la escala no son dos caminos equivalentes hacia el mismo lugar. Descartar los precios altos sube el Pearson a 0,544 y cuesta 6.869 vinos reales; el logaritmo llega a 0,618, un valor más alto, sin descartar una sola observación. Para esta variable la respuesta correcta a la asimetría es cambiar de escala, no recortar los datos.

6.4. Tratamiento adoptado

Por lo anterior no se eliminaron los valores atípicos de precio. Se conservaron todas las observaciones y se adoptó la escala logarítmica junto con estadísticos robustos, mediana y rango intercuartílico, para todo análisis que involucre el precio. Los dos errores encontrados quedaron documentados para revisión, sin corrección automática: decidir si un precio está mal pide criterio, y el procedimiento aporta la evidencia para ejercerlo.

Con *points* el análisis de atípicos casi no se puede aplicar. Ningún criterio marca más del 0,10% de las observaciones, y no porque la variable no tenga valores extremos sino porque ya viene recortada de origen: el umbral editorial de 80 puntos borró la cola inferior antes de que los datos llegaran al analista. Es una limitación del conjunto de datos, no una propiedad de los vinos.

7. Análisis comparativo entre variables

7.1. Relación entre precio y puntaje




Figura 6. Distribución del precio para cada puntaje, en escala logarítmica. La línea une las medianas.

Se representa la distribución del precio con diagramas de caja para cada puntaje, porque points toma apenas 21 valores distintos y funciona como agrupador natural. Un diagrama de dispersión con 120.000 observaciones daría una mancha uniforme sin información aprovechable.

En escala logarítmica la línea de medianas es casi recta a partir de los 86 puntos, señal de una relación aproximadamente exponencial: cada punto adicional multiplica el precio por un factor constante. Entre 80 y 85 la mediana se queda cerca de los 14 dólares, un piso de mercado, y desde ahí sube hasta unos 350 dólares en 100 puntos, veinticinco veces más.

La dispersión dentro de cada puntaje es amplia, así que el puntaje explica parte del precio pero no lo determina. Con un Spearman de 0,612 la asociación es fuerte sin ser determinista.

7.2. Comparación entre países




Figura 7. Distribución de puntajes en los doce países con mediana más alta, entre los que superan las 500 reseñas.

Se pide un mínimo de reseñas por país para que la comparación se sostenga: la mediana de un país con veinte reseñas no es comparable con la de uno que junta cincuenta mil, y sin ese filtro el ranking lo encabezarían países marginales por puro ruido muestral.

Austria y Alemania van primeros con mediana de 90 puntos, y Argentina y Chile quedan en 86. Estados Unidos, que aporta el 42% de las reseñas, tiene mediana de 88.

Estas diferencias no miden la calidad vitivinícola de cada país. Los países también difieren en qué variedades producen, en qué segmento de precio exportan y en qué catador cubre su región, así que la comparación directa mezcla el efecto del origen con el de esas otras variables. La sección 7.5 documenta un caso donde esa mezcla da vuelta la conclusión por completo.

Se usaron diagramas de caja y no de violín porque el violín estima la densidad con núcleos, un método que supone variable continua. Como points toma sólo 21 valores enteros, el suavizado inventa ondulaciones que son artefactos del método y no estructura de los datos.

7.3. El año de cosecha como variable derivada

El año de cosecha no es una columna, pero sale del título, que sigue el formato «bodega, año, nombre del vino, región».

Extraerlo con una expresión regular sobre el título completo produce un error sistemático, porque muchas bodegas llevan un año en su propio nombre. El patrón devuelve

1852 para «Hazlitt 1852 Vineyards 2005 Cabernet Sauvignon», cuando la cosecha es 2005. Afecta a unos 150 vinos y, como concentra años falsos en el siglo XIX, alcanza para arruinar cualquier análisis temporal. La solución aprovecha que *winery* existe como columna aparte y que el 100% de los títulos empieza con ella: se recorta ese prefijo y recién entonces se busca el año.

El 3,6% de las reseñas queda sin año. Son vinos espumantes rotulados «NV», mezclas de varias cosechas que legítimamente no tienen una. Se conservan como nulos, porque asignarles un año inventaría un dato que no existe.




Figura 8. Izquierda: puntaje medio por cosecha con el tamaño de muestra. Derecha: efecto del catador antes y después de controlar por país y variedad.

El panel izquierdo pide cautela. Las cosechas anteriores a 2003 tienen medias volátiles que se corresponden con muestras chicas, y arrastran un sesgo de supervivencia fuerte: de 1998 sólo se siguen reseñando los pocos vinos excepcionales que todavía se venden, mientras que de 2014 se reseña la producción corriente. Leer esas medias sin advertirlo llevaría a concluir que los vinos viejos son mejores, cuando lo que cambió es el filtro por el que entraron a la muestra.

7.4. Extensión de la nota de cata

La columna *description* es texto libre y no admite las frecuencias que se usan con las demás variables, pero sí una medida simple: cuántas palabras escribió el catador. Es la única variable que se puede derivar de esa columna sin entrar en procesamiento de lenguaje natural, y tiene interés porque la extensión de una reseña no la decide el vino sino quien la escribe.

Tabla 10. Correlación entre la extensión de la nota de cata y las variables numéricas.

Relación	Pearson	Spearman
Palabras y puntaje	0,538	0,528
Palabras y precio	0,350	0,345

Las notas tienen 40 palabras en promedio, con un mínimo de 3 y un máximo de 135. El promedio por puntaje crece de forma monótona sin una sola excepción: 26 palabras en los vinos de 80 puntos, 40 en los de 88, 53 en los de 94 y 70 en los de 100. Un vino de puntaje máximo recibe una reseña dos veces y media más larga que uno del piso de publicación.

La correlación de 0,538 con el puntaje es de las más altas del conjunto, más alta incluso que la del precio crudo con el puntaje. Admite dos lecturas que estos datos no permiten separar: que un vino más complejo da más material para describir, o que el catador se entusiasma y se explaya cuando algo le gusta. La correlación con el precio, 0,350, es bastante menor, lo que sugiere que la extensión sigue a la valoración más que al costo.

7.5. Efecto del catador y confusión por variable omitida

Comparando las medias crudas por catador aparecen diferencias de criterio que impresionan: 86,86 puntos para el más bajo contra 90,63 para la más alta, una brecha de 3,77 puntos, mayor que el desvío estándar de toda la variable.

Pero los catadores no reciben los vinos al azar: cada uno cubre las regiones de su especialidad. El catador de media más baja reseña 43% de vinos españoles y 29% de chilenos; la catadora de media más alta, 60% austríacos y 38% franceses. La diferencia de puntajes bien podría venir de los vinos y no de quien los evalúa.

Para separar las dos cosas se midió, en cada reseña, cuánto se aparta del promedio de su propio grupo de país y variedad. Ese desvío contesta la pregunta que importa: frente al mismo tipo de vino, ¿este catador puntúa por encima o por debajo de lo habitual?

Tabla 11. Puntaje medio por catador antes y después de controlar por país y variedad.

Catador	Reseñas	Media cruda	Desvío controlado
Anne Krebiehl MW	3.290	90,63	+0,76

Catador	Reseñas	Media cruda	Desvío controlado
Matt Kettmann	5.730	90,06	+0,85
Virginie Boone	8.708	89,22	+0,20
Paul Gregutt	8.868	89,09	-0,00
Kerin O'Keefe	9.697	88,90	+0,01
Roger Voss	23.560	88,73	-0,04
Anna Lee C. Iijima	4.017	88,42	-0,55
Michael Schachner	14.046	86,86	-0,02

La brecha de 3,77 puntos cae a 0,78, y el catador que parecía el más severo puntúa en el promedio exacto de los vinos que evalúa, con un desvío de -0,02. Casi toda la diferencia venía de qué vinos le tocaban. Es confusión por una variable omitida, y comparar las medias crudas habría llevado a una conclusión equivocada sobre el trabajo de personas con nombre y apellido.

8. Conclusiones

Del análisis salen conclusiones sobre el conjunto de datos y sobre el método usado para analizarlo.

Sobre los datos: el archivo llegó con tres formas independientes de corrupción que ninguna carga convencional avisa con un error, y el enunciado que lo acompaña describe mal tanto el número de columnas como el de reseñas. El 7,7% de las filas estaba duplicado. El precio se comporta como log-normal y tiene ausencias condicionadas por el origen geográfico; el puntaje viene censurado de origen por el umbral editorial de publicación.

Sobre los hallazgos: el precio crece de forma aproximadamente exponencial con el puntaje, con una correlación de rangos de 0,612 que indica asociación fuerte pero no determinista. La extensión de la nota de cata acompaña al puntaje todavía más de cerca, con 0,538. Y las diferencias de puntaje entre países y entre catadores se achican muchísimo al controlar por las variables que en realidad deciden qué vino evalúa cada quién.

Sobre el método, tres decisiones concentran el valor del trabajo. Fijar criterios de verificación antes de cargar los datos, que fue lo que permitió detectar una corrupción silenciosa. Elegir la estrategia de imputación midiendo el error sobre datos ocultos a propósito, en vez de aplicar una convención. Y distinguir el valor extremo correcto del error de registro comparando contra el contexto, en vez de recortar la cola de la distribución por criterio puramente estadístico.

Las limitaciones vienen casi todas del conjunto de datos y no del procedimiento. La censura en 80 puntos impide describir la distribución real de calidad. La concentración del 42% de las reseñas en un solo país limita hasta dónde se puede generalizar cualquier conclusión global. Y de la columna de descripción, que el enunciado señala como la más relevante, este trabajo usa sólo su extensión: el análisis del contenido de las notas de cata con técnicas de procesamiento de lenguaje natural es la continuación natural del trabajo.

9. Referencias

- McKinney, W. (2022). Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter (3.^a ed.). O'Reilly Media.
- Little, R. J. A. y Rubin, D. B. (2019). Statistical Analysis with Missing Data (3.^a ed.). Wiley.
- Iglewicz, B. y Hoaglin, D. C. (1993). How to Detect and Handle Outliers. ASQC Quality Press.
- Tukey, J. W. (1977). Exploratory Data Analysis. Addison-Wesley.
- WineEnthusiast. Conjunto de datos winemag-data-130k-v2, provisto con el enunciado de la actividad.

Anexo. Estructura del script

El código se entrega en `analisis_exploratorio_vinos.py`, organizado en seis secciones que se corresponden con las de este informe. Se ejecuta con «`python analisis_exploratorio_vinos.py`» y necesita `pandas`, `numpy`, `matplotlib`, `scipy` y `openpyxl`. La corrida completa tarda unos catorce segundos y deja las ocho figuras en el directorio `graficos/`.

El script busca el archivo de datos en dos formatos y usa el primero que encuentre: `winemag-data-130k-v2.csv`, que lee directo, o el `.xlsx` entregado con el enunciado, que reconstruye antes de leer. Los dos caminos devuelven el mismo `DataFrame`.

Tabla 12. Correspondencia entre las secciones del script y las de este informe.

Sección	Funciones principales
1. Carga de datos	<code>cargar_datos</code> , <code>_reconstruir_lineas</code> , <code>_reparar_codificacion</code> , <code>_elegir_ruta</code>
2. Perfilado y depuración	<code>perfil_columnas</code> , <code>resumen_categoricas</code> , <code>quitar_duplicados</code>
3. Visualización	<code>grafico_puntajes</code> , <code>grafico_precios</code> , <code>grafico_categoricas</code> , <code>grafico_precio_vs_puntaje</code> , <code>grafico_puntaje_por_pais</code>
4. Datos faltantes	<code>diagnostico_faltantes</code> , <code>validar_imputacion_precio</code> , <code>imputar_precio</code> , <code>tratar_faltantes</code> , <code>grafico_faltantes</code>
5. Datos atípicos	<code>detectar_atipicos</code> , <code>atipicos_contextuales</code> , <code>impacto_atipicos</code> , <code>grafico_atipicos</code>
6. Análisis comparativo	<code>extraer_anio</code> , <code>analisis_temporal</code> , <code>efecto_catador</code> , <code>agregar_longitud</code> , <code>analisis_longitud</code> , <code>mejor_relacion_calidad_precio</code> , <code>grafico_comparativo</code>

La función de carga lleva aserciones que verifican la forma del conjunto y el tipo de las variables numéricas, además de que cada línea reconstruida dé los catorce campos esperados. Si el archivo de origen cambia, el script falla de forma visible en lugar de seguir sobre datos distintos de los analizados.