

Análisis exploratorio de datos de reseñas de vinos

Trabajo Práctico 2 — Seminario de Programación para Ciencia de Datos

Lucas Llano

22 de septiembre de 2026

Conjunto de datos: winemag-data-130k-v2 (WineEnthusiast)

Índice

1. Introducción	3
2. Descripción del conjunto de datos	3
3. Carga e integridad del archivo	4
3.1. Delimitador de campos incorrecto	4
3.2. Reseñas repartidas en varias filas	5
3.3. Codificación de caracteres.....	5
3.4. Verificación de la carga.....	6
4. Análisis exploratorio	6
4.1. Estructura y valores repetidos	6
4.2. Resumen estadístico de las variables numéricas	7
4.3. Distribución de los puntajes	7
4.4. Distribución de los precios	8
4.5. Variables categóricas.....	9
5. Tratamiento de datos faltantes.....	10
5.1. Cuantificación y co-ocurrencia	10
5.2. El faltante estructural como información	12
5.3. Diagnóstico del mecanismo de ausencia del precio	12
5.4. Selección de la estrategia mediante validación	13
5.5. Decisiones adoptadas y prevención de circularidad.....	14
6. Análisis de datos atípicos	14
6.1. Comparación de criterios de detección	14
6.2. Naturaleza y causa: la extremidad estadística no identifica errores.....	15
6.3. Impacto sobre las conclusiones	17
6.4. Tratamiento adoptado.....	17
7. Análisis comparativo entre variables	18
7.1. Relación entre precio y puntaje	18

7.2. Comparación entre países.....	19
7.3. El año de cosecha como variable derivada.....	20
7.4. Efecto del catador y confusión por variable omitida.....	21
8. Conclusiones	22
9. Referencias	22
Anexo. Estructura del script	24

1. Introducción

El presente informe documenta un análisis exploratorio sobre un conjunto de 129.971 reseñas de vinos publicadas por WineEnthusiast. El objetivo es comprender la estructura de los datos, detectar y corregir sus defectos, y extraer conclusiones sustentadas sobre las características, precios y calificaciones de los vinos reseñados.

El trabajo se organiza en seis etapas que se corresponden con las secciones del script entregado: carga e integridad del archivo, perfilado estructural, análisis descriptivo y visual, tratamiento de datos faltantes, análisis de datos atípicos y análisis comparativo entre variables.

Una advertencia metodológica recorre todo el informe y conviene enunciarla desde el comienzo: **la ausencia de un mensaje de error no es evidencia de que los datos sean correctos**. El archivo entregado se carga sin lanzar excepciones y, pese a ello, llega al analista con tres formas independientes de corrupción. Detectarlas exigió definir criterios de verificación antes de la carga, y no después.

2. Descripción del conjunto de datos

El conjunto reúne reseñas de vinos con información sobre su origen geográfico, la variedad de uva, la bodega productora, el precio de una botella, el puntaje asignado y la nota de cata redactada por el catador. Cada fila corresponde a una reseña.

El enunciado de la actividad describe el archivo como un conjunto de 130.000 reseñas distribuidas en 10 columnas. La verificación contra el archivo real arroja 129.971 reseñas y 13 columnas. La discrepancia en el número de columnas no es de redondeo: el propio enunciado enumera trece nombres de campo en su descripción detallada, de modo que se contradice a sí mismo dentro de la misma página.

Se adopta como criterio que **los datos son la única evidencia de lo que el archivo contiene**, mientras que el enunciado constituye una afirmación a verificar. Conviene precisar que de esta discrepancia no se sigue que el archivo sea correcto, sino únicamente que al menos una de las dos fuentes es errónea. Como se verá en la sección 3, en este caso ambas lo son.

Tabla 1. Variables del conjunto de datos y su naturaleza analítica.

Variable	Tipo	Descripción
country	Categórica	País de origen del vino (43 valores)

Variable	Tipo	Descripción
description	Texto libre	Nota de cata redactada por el catador
designation	Categórica	Viñedo específico dentro de la bodega
points	Numérica discreta	Puntaje de 80 a 100 asignado por WineEnthusiast
price	Numérica continua	Precio de una botella en dólares
province	Categórica	Provincia o estado de origen (425 valores)
region_1	Categórica	Área vinícola dentro de la provincia
region_2	Categórica	Sub-área vinícola (sólo Estados Unidos)
taster_name	Categórica	Catador que realizó la reseña (19 valores)
taster_twitter_handle	Categórica	Usuario de Twitter del catador
title	Texto libre	Título de la reseña; incluye el año de cosecha
variety	Categórica	Variedad de uva (707 valores)
winery	Categórica	Bodega productora (16.757 valores)

Merece atención una segunda contradicción del enunciado, esta vez informativa y no errónea. Al describir *points* señala que la escala va de 1 a 100 y, en la misma línea, que sólo se publican reseñas con puntaje de 80 o más. La variable observada está por lo tanto **censurada**: no describe la calidad de los vinos evaluados sino la de aquellos que superaron el umbral de publicación. Esta característica condiciona la interpretación de toda la sección 6.

3. Carga e integridad del archivo

La consigna indica cargar el archivo winemag-data-130k-v2.csv. El material entregado, en cambio, es un archivo con extensión .xlsx de 21 MB. No se trata de una hoja de cálculo con datos tabulados, sino del mismo CSV tras una importación mal configurada en Excel. La inspección reveló tres defectos de distinto origen.

3.1. Delimitador de campos incorrecto

Al abrir el archivo con la configuración obvia, las trece columnas esperadas aparecen como cinco: una que contiene la línea CSV completa y cuatro con nombre genérico, mayormente vacías. El recuento de valores no nulos de esas cuatro columnas decrece en cascada —2.956, 159, 12 y 1—, patrón característico de un texto partido por un separador que la mayoría de las líneas no contiene.

La inspección de una fila afectada muestra el corte en mitad de una oración: la descripción termina en «passion fruit and kiwi» y la celda siguiente comienza en «a sprinkling of graham cracker». El signo que unía ambas cláusulas desapareció, porque un analizador sintáctico consume su propio delimitador.

El carácter se identificó por dos vías independientes y coincidentes. La primera, gramatical: el punto y coma es el único signo que une dos cláusulas independientes con minúscula a continuación. La segunda, empírica y más concluyente: si Excel empleó un carácter como delimitador, lo eliminó de todo el archivo, de modo que el delimitador debe ser el signo de puntuación **ausente por completo** del texto. El recuento sobre las 129.975 líneas arroja decenas de miles de comas y de puntos, y cero punto y coma en 130.000 reseñas redactadas por críticos profesionales. La reversión consiste en reunir las celdas no vacías de cada fila interponiendo ese carácter.

3.2. Reseñas repartidas en varias filas

Cuatro descripciones contenían saltos de línea dentro del propio texto y quedaron distribuidas en más de una fila de la hoja de cálculo. Se detectan porque toda línea de datos válida comienza con el índice numérico seguido de coma; una línea que no respeta ese patrón es la continuación de la anterior y debe reunirse con ella. De no corregirse, el conjunto habría quedado con cuatro registros espurios y cuatro descripciones truncadas.

3.3. Codificación de caracteres

El texto presentaba *mojibake*: «Gewürztraminer» aparecía como «GewÃ¼rztraminer» y «Albariño» como «AlbariÃ±o». El fenómeno se produce cuando una secuencia de bytes UTF-8 se interpreta byte a byte con la codificación cp1252. La reversión es exacta: se vuelve a codificar el texto en cp1252 para recuperar los bytes originales y se decodifica como UTF-8. El procedimiento reparó 106.477 de las 106.611 celdas afectadas; las 134 restantes corresponden a comillas tipográficas cuya secuencia incluye posiciones que cp1252 no define.

La función es segura sobre texto ya correcto: una cadena ASCII atraviesa la conversión sin cambios y una con acentos legítimos falla al decodificar y se devuelve intacta, de modo que no puede corromper lo que estaba bien.

3.4. Verificación de la carga

El criterio de éxito se definió antes de ejecutar la carga, para no razonar sobre un resultado ya obtenido. Dado que el encabezado declara trece nombres de columna precedidos por un campo de índice sin nombre, **toda línea reconstruida debe producir exactamente catorce campos al analizarse como CSV**. La verificación se satisface sin excepciones sobre las 129.972 líneas, encabezado incluido. El script conserva estas condiciones como aserciones, de modo que falle de forma visible si el archivo de origen cambia.

El resultado de la carga es un conjunto de 129.971 reseñas por 13 columnas, con points de tipo entero y price de tipo decimal.

4. Análisis exploratorio

4.1. Estructura y valores repetidos

El perfilado inicial revela dos grupos de variables claramente distintos. Por un lado, categóricas de baja cardinalidad aptas para análisis de frecuencias: country con 43 valores, taster_name con 19, region_2 con 17. Por otro, campos de cardinalidad cercana al total, que son texto libre o identificadores y no admiten ese tratamiento: description alcanza el 92,3% de valores únicos y title el 91,4%.

Que ninguno de esos dos campos llegue al 100% conduce a un hallazgo relevante: el conjunto contiene **9.983 pares de filas idénticas** en las trece columnas. Comparar únicamente por descripción o por título arroja el mismo número, lo que confirma que se trata de filas enteramente repetidas y no de reseñas distintas que compartan texto. El origen más plausible es la extracción del sitio web.

Se eliminaron conservando la primera aparición de cada una, decisión que no responde a criterios de prolijidad sino de validez: con el 7,7% de las filas duplicadas, esas reseñas pesarían el doble en toda media, frecuencia, ranking y correlación posterior, sesgando los resultados hacia aquello que la extracción repitió. El conjunto de trabajo queda en 119.988 reseñas.

4.2. Resumen estadístico de las variables numéricas

Tabla 2. Resumen estadístico de las variables numéricas.

Estadístico	points	price
Media	88,45	35,36
Mediana	88,00	25,00
Desvío estándar	3,04	41,02
Mínimo	80,00	4,00
Máximo	100,00	3.300,00
Rango intercuartílico	5,00	25,00
Asimetría	0,05	18,00
Curtosis	-0,30	829,52
Coefficiente de variación	0,03	1,16

Las dos variables exigen tratamientos opuestos. *points* es prácticamente simétrica: su asimetría de 0,05 y la coincidencia entre media y mediana permiten emplear media y desvío estándar como medidas de resumen. *price*, en cambio, presenta una asimetría de 18,00 y una curtosis de 829,52, valores extremos frente al 0 que corresponde a una distribución normal. Su media supera a la mediana en un 41% y su máximo equivale a 132 veces la mediana.

De ello se desprende una regla operativa que se aplica en el resto del informe: para *price* se emplean mediana y rango intercuartílico en lugar de media y desvío, y escala logarítmica en toda representación gráfica.

4.3. Distribución de los puntajes




Figura 1. Distribución de puntajes. La barrera vertical en 80 responde al umbral de publicación, no a la ausencia de vinos por debajo de ese valor.

La distribución es aproximadamente simétrica y unimodal en torno a 88 puntos, pero exhibe un corte abrupto en 80 sin cola izquierda alguna. Ese corte no es una característica de los vinos sino del criterio editorial: WineEnthusiast no publica reseñas por debajo de ese puntaje.

La consecuencia interpretativa es considerable. Afirmar que «el vino promedio obtiene 88 puntos» constituye un artefacto de sesgo de selección y no un hallazgo sobre la calidad de los vinos. La variable describe a los vinos publicados, que son una muestra deliberadamente no representativa de los vinos evaluados.

4.4. Distribución de los precios




Figura 2. La misma variable bajo dos escalas. La asimetría cae de 18,00 a 0,60 al aplicar el logaritmo.

El panel izquierdo muestra por qué la escala lineal resulta inservible para esta variable: la asimetría comprime el 99% de las observaciones contra el eje vertical y deja el resto del gráfico vacío. El panel derecho presenta los mismos datos en escala logarítmica, donde la distribución se revela aproximadamente simétrica y con una asimetría de 0,60.

El precio se comporta, por lo tanto, como una variable **log-normal**. El uso del logaritmo no es un recurso estético sino el reconocimiento de la escala en la que la variable es naturalmente simétrica, y de ello dependen las conclusiones de la sección 6.

4.5. Variables categóricas




Figura 3. Quince categorías más frecuentes de las cuatro variables categóricas principales.

La concentración geográfica es pronunciada. Estados Unidos aporta el 42% de las reseñas y los tres primeros países reúnen el 72%; las diez primeras categorías cubren el 95,9% del conjunto. El patrón se repite en province, donde California concentra por sí sola el 28%.

La variable winery presenta el comportamiento opuesto: con 16.757 bodegas distintas, las quince más frecuentes apenas alcanzan el 2% del total. Se trata de una cola larga extrema en la que ninguna bodega individual resulta representativa, lo que desaconseja cualquier análisis comparativo a ese nivel de agregación.

5. Tratamiento de datos faltantes

5.1. Cuantificación y co-ocurrencia




Figura 4. Faltantes por columna y probabilidad condicional de co-ocurrencia entre pares de columnas.

Tabla 3. Valores faltantes por columna y mecanismo diagnosticado.

Variable	Faltantes	%	Mecanismo
region_2	79.460	61,1	Estructural
designation	37.465	28,8	Estructural
taster_twitter_handle	31.213	24,0	Dependiente
taster_name	26.244	20,2	No informado
region_1	21.247	16,3	Estructural
price	8.996	6,9	MAR
province	63	0,05	Desconocido
country	63	0,05	Desconocido
variety	1	0,00	Desconocido

El panel derecho de la Figura 4 permite distinguir faltantes estructurales de aleatorios mediante probabilidades condicionales. Dos resultados son concluyentes. La probabilidad de que falte *taster_twitter_handle* dado que falta *taster_name* es exactamente 1,00: la segunda columna es una función de la primera y su ausencia no aporta información adicional. Y la probabilidad de que falte *region_2* dado que falta *price* asciende a 0,98, lo que indica que ambos faltantes comparten una causa común: el origen geográfico.

5.2. El faltante estructural como información

El error más frecuente ante una columna con 61% de valores ausentes consiste en descartarla. La verificación demuestra que sería un error grave: *region_2* está presente en el 92,7% de los vinos estadounidenses y en **exactamente cero** reseñas del resto del mundo. No es una columna incompleta sino una columna completa para el subconjunto en el que tiene sentido, ya que designa sub-apelaciones propias del sistema vitivinícola de Estados Unidos.

Un razonamiento análogo se aplica a *designation* y *region_1*: no todo vino procede de un viñedo designado ni de un área vinícola delimitada. En estos casos el valor ausente no representa un dato perdido sino la categoría «no aplica», y sustituirlo por una etiqueta explícita conserva esa información, mientras que imputarlo fabricaría un dato que nunca existió.

5.3. Diagnóstico del mecanismo de ausencia del precio

El precio es la única variable cuyo faltante constituye un dato genuinamente perdido y, por lo tanto, la única candidata a imputación. Determinar el mecanismo es lo que decide la estrategia adecuada.

- **MCAR** (ausencia completamente aleatoria): no se relaciona con ninguna variable. Cualquier imputación razonable resulta aceptable y eliminar las filas afectadas no introduce sesgo.
- **MAR** (ausencia aleatoria condicionada): depende de variables que sí se observan. Imputar con un valor global sesga el resultado; es necesario condicionar.
- **MNAR** (ausencia no aleatoria): depende del propio valor faltante y no es corregible sólo con los datos disponibles.

Tabla 4. Proporción de precios ausentes por país, en países con al menos 1.000 reseñas.

País	Reseñas	% sin precio
Francia	20.353	20,0
Austria	3.034	16,4
Portugal	5.256	14,3
Italia	17.940	13,6
Sudáfrica	1.301	8,1

País	Reseñas	% sin precio
Nueva Zelanda	1.278	3,0
Argentina	3.544	1,2
España	6.116	1,1
Estados Unidos	50.457	0,4

Francia presenta cincuenta veces más precios ausentes que Estados Unidos, y la proporción crece además con el puntaje, del 0,5% entre los vinos de 80 puntos al 15,2% entre los de 99. La ausencia depende claramente de variables observadas, de modo que el mecanismo es **MAR**. La consecuencia es directa: imputar con la mediana general asignaría precios propios del mercado estadounidense, más económico, a vinos franceses e italianos.

5.4. Selección de la estrategia mediante validación

La elección del método de imputación no se resolvió por criterio general sino por medición. Se ocultó una muestra de precios efectivamente conocidos, se imputó cada estrategia candidata y se midió el error contra el valor real, disponible en esas filas.

El ocultamiento replicó el patrón MAR observado —ocultando proporcionalmente más en los países que efectivamente presentan más ausencias— en lugar de seleccionar filas al azar. Evaluar contra un patrón MCAR artificial habría favorecido indebidamente a los métodos globales, que son precisamente los que fallan cuando la ausencia se concentra.

Tabla 5. Error de cada estrategia de imputación sobre precios ocultados deliberadamente.

Estrategia	MAE	Error mediano	MAPE
Media global	\$24,35	\$17,44	61,1%
Mediana global	\$21,96	\$10,00	47,1%
Mediana por país	\$21,66	\$10,00	44,4%
Mediana por variedad	\$19,57	\$9,00	35,9%

Estrategia	MAE	Error mediano	MAPE
Mediana por país y variedad	\$18,73	\$8,00	33,3%
Mediana por país, variedad y puntaje	\$14,92	\$6,00	25,0%

La estrategia adoptada reduce el error absoluto medio de \$21,96 a \$14,92 y el error porcentual mediano del 47% al 25% respecto de la mediana global. La incorporación del puntaje al agrupador es la que más contribuye, resultado coherente con la relación exponencial entre precio y puntaje documentada en la sección 7.1. Se emplean medianas y no medias porque, dentro de cada grupo, la media continúa inflada por unas pocas botellas muy costosas. Una cascada de respaldos, del agrupamiento más específico al más general, garantiza que no subsistan valores nulos.

5.5. Decisiones adoptadas y prevención de circularidad

No se eliminó ninguna fila. Las 63 reseñas sin país y la única sin variedad conservan puntaje, precio y descripción válidos: descartarlas habría supuesto perder esa información sin contrapartida, mientras que etiquetarlas como «Desconocido» deja la ignorancia declarada y visible en cualquier tabla de frecuencias.

Cada precio imputado quedó señalado mediante una columna auxiliar. La precaución es necesaria porque la imputación emplea *points* como variable de agrupamiento: analizar la relación entre precio y puntaje sobre valores generados a partir del puntaje reforzaría artificialmente esa misma relación. Se trata de un caso de **circularidad**, y la columna auxiliar permite excluir los valores sintéticos de todo análisis donde comprometan la conclusión. Los análisis de las secciones 6 y 7.1 se realizaron exclusivamente sobre precios observados.

6. Análisis de datos atípicos


6.1. Comparación de criterios de detección

Tabla 6. Proporción de observaciones señaladas como atípicas según el criterio empleado.

Criterio	% en price	% en points
Rango intercuartílico clásico	6,16	0,04
Puntuación z, $ z > 3$	0,97	0,10
z modificado sobre la MAD, $ z > 3,5$	6,41	0,04
Rango intercuartílico sobre $\log(x)$	0,97	0,02

Los criterios discrepan por un factor de seis sobre la misma variable, y la discrepancia constituye en sí misma un hallazgo. El rango intercuartílico clásico presupone una distribución aproximadamente simétrica; aplicado a una variable con asimetría 18 termina señalando el 6,16% de las observaciones, que no son casos excepcionales sino la cola natural de la distribución.

La puntuación z incurre en un defecto distinto: emplea media y desvío estándar, que son precisamente los estadísticos que los valores extremos distorsionan, de modo que el criterio resulta circular y sub-detecta. El z modificado corrige ese problema sustituyéndolos por mediana y desviación absoluta mediana, robustas ante valores extremos. El rango intercuartílico aplicado sobre el logaritmo es el más defendible para esta variable, ya que aplica el criterio sobre la escala en que efectivamente es simétrica.

**Figura 5.** Umbrales de los dos criterios más discrepantes y distribución del cociente contra el grupo de pares.

6.2. Naturaleza y causa: la extremidad estadística no identifica errores

Los criterios anteriores responden a la pregunta «¿es un valor extremo?». La consigna requiere responder otra: «¿es un error?». Y esa distinción no se resuelve observando la distribución global.

Château Pétrus a 2.500 dólares y Château Margaux a 1.900 son valores extremos y correctos: esos vinos se comercializan efectivamente a esos precios. Un Médoc corriente a 3.300 dólares es igual de extremo y no puede serlo. Ambos superan cualquier umbral estadístico, pero exigen tratamientos opuestos.

Para separarlos se comparó cada precio con la mediana de su **grupo de pares**, definido como el conjunto de vinos de la misma provincia y el mismo puntaje. Un vino costoso entre vinos costosos arroja un cociente próximo a 1; un vino costoso entre vinos económicos se delata. La distribución de cocientes concentra su masa alrededor de 1 y sitúa el percentil 99,9 en 7,3, de modo que un umbral de 10 queda fuera del alcance de la variación legítima de mercado.

Tabla 7. Precios más alejados de su grupo de pares.

Vino	Puntos	Precio	Pares	Cociente
Château les Ormes Sorbet 2013 Médoc	88	\$3.300	\$20	165,0
Blair 2013 Roger Rose Chardonnay	91	\$2.013	\$40	50,3
Domaine Pellé 2014 Morogues Rosé	87	\$800	\$20	40,0
Burmester 1963 Colheita Port	87	\$790	\$25	31,6
Henschke 2009 Hill of Grace Shiraz	91	\$780	\$30	26,0
Château Pétrus 2014 Pomerol	96	\$2.500	\$175	14,3

El procedimiento identificó dos errores de carga con evidencia concluyente:

- **Blair 2013 Roger Rose Chardonnay, \$2.013.** El precio coincide exactamente con el año de cosecha consignado en el título. La misma bodega comercializa sus otros siete vinos entre 22 y 75 dólares, y la cosecha 2012 de este mismo vino figura a 28 dólares. Todo indica que el año se registró en el campo de precio.

- **Château les Ormes Sorbet 2013 Médoc, \$3.300.** Es el único vino de Burdeos con 88 puntos que supera los 50 dólares, sobre una base de 519 casos cuya mediana es de 20. El precio equivale a 165 veces el de su grupo de pares.

En contraste, el Oporto Burmester de 1963 a 790 dólares y el Château Pétrus a 2.500 constituyen valores legítimos: un cociente elevado en vinos de guarda excepcional o de denominaciones de prestigio refleja el mercado real y no un error de registro.

6.3. Impacto sobre las conclusiones

Tabla 8. Correlación entre precio y puntaje bajo distintos tratamientos de los atípicos.

Escenario	n	Pearson	Spearman
Precio crudo, con atípicos	111.593	0,417	0,612
Precio crudo, sin atípicos por IQR	104.724	0,544	0,572
Logaritmo del precio, con atípicos	111.593	0,618	0,612

El coeficiente de Pearson mide asociación lineal; aplicado sobre una variable con asimetría 18 subestima la relación real y arroja 0,417. El de Spearman opera sobre rangos, es insensible a transformaciones monótonas de escala y por eso apenas se mueve entre escenarios: constituye la referencia robusta contra la cual comparar.

El resultado central de la sección es que eliminar atípicos y transformar la escala no son dos caminos equivalentes hacia el mismo destino. Descartar los precios altos eleva el coeficiente de Pearson a 0,544 al precio de perder 6.869 vinos reales; el logaritmo alcanza 0,618, un valor superior, **sin descartar una sola observación**. Para esta variable, la respuesta correcta a la asimetría consiste en cambiar de escala y no en recortar los datos.

6.4. Tratamiento adoptado

En coherencia con lo anterior, no se eliminaron los valores atípicos de precio. Se conservó la totalidad de las observaciones y se adoptó la escala logarítmica junto con estadísticos robustos —mediana y rango intercuartílico— para todo análisis que involucre el precio. Los dos errores identificados quedaron documentados para su revisión, sin corrección

automática: determinar si un precio es erróneo requiere criterio, y el procedimiento aporta la evidencia para ejercerlo.

En el caso de *points* el análisis de atípicos resulta prácticamente inaplicable. Ningún criterio señala más del 0,10% de las observaciones, y no porque la variable carezca de valores extremos sino porque ya viene recortada en origen: el umbral editorial de 80 puntos eliminó la cola inferior antes de que los datos llegaran al analista. Se trata de una limitación del conjunto de datos y no de una propiedad de los vinos.

7. Análisis comparativo entre variables

7.1. Relación entre precio y puntaje




Figura 6. Distribución del precio para cada puntaje, en escala logarítmica. La línea une las medianas.

Se representa la distribución del precio mediante diagramas de caja para cada puntaje, ya que *points* toma únicamente 21 valores distintos y constituye un agrupador natural. Un diagrama de dispersión con 120.000 observaciones produciría una mancha uniforme sin información aprovechable.

En escala logarítmica la línea de medianas es sensiblemente recta a partir de los 86 puntos, lo que indica una relación aproximadamente exponencial: cada punto adicional multiplica el precio por un factor constante. Entre 80 y 85 puntos la mediana permanece estable en torno a los 14 dólares, valor que opera como un piso de mercado, y a partir de allí asciende hasta unos 350 dólares en 100 puntos, es decir veinticinco veces.

La dispersión dentro de cada puntaje es considerable, de modo que el puntaje explica parte del precio pero dista de determinarlo. Con un coeficiente de Spearman de 0,612, la asociación es sólida sin ser determinista.

7.2. Comparación entre países




Figura 7. Distribución de puntajes en los doce países con mediana más alta, entre los que superan las 500 reseñas.

Se exige un mínimo de reseñas por país para que la comparación resulte sostenible: la mediana de un país con veinte reseñas no es comparable con la de uno que reúne cincuenta mil, y omitir ese filtro situaría en los primeros puestos a países marginales por efecto del ruido muestral.

Austria y Alemania encabezan el ordenamiento con mediana de 90 puntos, mientras que Argentina y Chile se sitúan en 86. Estados Unidos, pese a aportar el 42% de las reseñas, obtiene una mediana de 88.

Estas diferencias no deben interpretarse como una medida de la calidad vitivinícola de cada país. Los países difieren también en qué variedades producen, en qué segmentos de precio exportan y en qué catador cubre su región, de modo que la comparación directa confunde el efecto del origen con el de esas otras variables. La sección siguiente documenta un caso en el que ese tipo de confusión invierte por completo la conclusión.

Se emplearon diagramas de caja en lugar de diagramas de violín porque estos últimos estiman la densidad mediante núcleos, un método que presupone variable continua. Como

points toma sólo 21 valores enteros, el suavizado genera ondulaciones que son artefactos del método y no estructura de los datos.

7.3. El año de cosecha como variable derivada

El año de cosecha no figura como columna, pero puede derivarse del título, que sigue el formato «bodega, año, nombre del vino, región».

La extracción directa mediante una expresión regular sobre el título completo produce un error sistemático: numerosas bodegas incorporan un año a su propia denominación. El patrón devuelve 1852 para «Hazlitt 1852 Vineyards 2005 Cabernet Sauvignon», cuando la cosecha es 2005. El defecto afecta a unos 150 vinos y, dado que concentra años espurios en el siglo XIX, bastaría para invalidar cualquier análisis temporal. La solución aprovecha que *winery* existe como columna independiente y que el 100% de los títulos comienza con ella: se recorta ese prefijo y recién entonces se busca el año.

El 3,6% de las reseñas queda sin año. Corresponden a vinos espumantes rotulados «NV», mezclas de varias cosechas que legítimamente carecen de uno. Se conservan como nulos, ya que asignarles un año fabricaría un dato inexistente.




Figura 8. Izquierda: puntaje medio por cosecha con el tamaño de muestra. Derecha: efecto del catador antes y después de controlar por país y variedad.

El panel izquierdo debe leerse con cautela. Las cosechas anteriores a 2003 presentan medias volátiles que se corresponden con muestras reducidas, y operan bajo un sesgo de supervivencia severo: de 1998 sólo continúan reseñándose los pocos vinos excepcionales que aún se comercializan, mientras que de 2014 se reseña la producción corriente. Comparar esas medias sin advertirlo conduciría a concluir que los vinos antiguos son mejores, cuando lo que cambió es el criterio por el cual ingresaron a la muestra.

7.4. Efecto del catador y confusión por variable omitida

La comparación de las medias crudas por catador sugiere diferencias notables de criterio: 86,86 puntos para el más bajo frente a 90,63 para la más alta, una brecha de 3,77 puntos superior al desvío estándar de la variable completa.

Sin embargo, los catadores no reciben los vinos al azar: cada uno cubre las regiones de su especialidad. El catador de media más baja reseña 43% de vinos españoles y 29% de chilenos; la catadora de media más alta, 60% austriacos y 38% franceses. La diferencia de puntajes podría por lo tanto atribuirse a los vinos y no a quien los evalúa.

Para separar ambos efectos se midió, para cada reseña, cuánto se aparta del promedio de su propio grupo de país y variedad. Ese desvío responde la pregunta pertinente: ante el mismo tipo de vino, ¿este catador puntúa por encima o por debajo de lo habitual?

Tabla 9. Puntaje medio por catador antes y después de controlar por país y variedad.

Catador	Reseñas	Media cruda	Desvío controlado
Anne Krebiehl MW	3.290	90,63	+0,76
Matt Kettmann	5.730	90,06	+0,85
Virginie Boone	8.708	89,22	+0,20
Paul Gregutt	8.868	89,09	-0,00
Kerin O'Keefe	9.697	88,90	+0,01
Roger Voss	23.560	88,73	-0,04
Anna Lee C. Iijima	4.017	88,42	-0,55
Michael Schachner	14.046	86,86	-0,02

El resultado es concluyente: la brecha de 3,77 puntos se reduce a 0,78, y el catador que aparentaba ser el más severo puntúa en el promedio exacto de los vinos que evalúa (-0,02). Prácticamente toda la diferencia aparente era **asignación de vinos y no criterio de evaluación**. Se trata de un caso de confusión por variable omitida, y comparar las medias crudas habría conducido a una conclusión equivocada sobre el desempeño profesional de personas concretas.

8. Conclusiones

El análisis permite extraer conclusiones sobre el conjunto de datos y sobre el método empleado para analizarlo.

Respecto del conjunto de datos, se verificó que llegó al analista con tres formas independientes de corrupción que ninguna carga convencional señala mediante un error, y que el enunciado que lo acompaña describe incorrectamente tanto el número de columnas como el de reseñas. El 7,7% de las filas estaba duplicado. La variable de precio se comporta como log-normal y presenta ausencias condicionadas por el origen geográfico; la de puntaje está censurada en origen por el umbral editorial de publicación.

Respecto de los hallazgos sustantivos, el precio crece de forma aproximadamente exponencial con el puntaje, con una correlación de rangos de 0,612 que indica asociación sólida pero no determinista. Las diferencias de puntaje entre países y entre catadores se reducen de manera drástica al controlar por las variables que efectivamente determinan qué vino evalúa cada quién.

Respecto del método, tres decisiones concentran el valor del trabajo. La primera es haber definido criterios de verificación antes de cargar los datos, lo que permitió detectar una corrupción silenciosa. La segunda es haber elegido la estrategia de imputación mediante validación medida sobre datos ocultos deliberadamente, en lugar de aplicar una convención. La tercera es haber distinguido el valor extremo correcto del error de registro mediante comparación contextual, en lugar de descartar la cola de la distribución por criterio puramente estadístico.

Las limitaciones del análisis derivan en su mayoría del conjunto de datos y no del procedimiento. La censura en 80 puntos impide describir la distribución real de calidad. La concentración del 42% de las reseñas en un único país restringe la generalización de cualquier conclusión global. Y la columna de descripción, que el enunciado señala como la más relevante, contiene texto que este informe no explota: su análisis mediante procesamiento de lenguaje natural constituye la continuación natural del trabajo.

9. Referencias

McKinney, W. (2022). Python for Data Analysis: Data Wrangling with pandas, NumPy, and Jupyter (3.^a ed.). O'Reilly Media.

Little, R. J. A. y Rubin, D. B. (2019). *Statistical Analysis with Missing Data* (3.^a ed.). Wiley.

Iglewicz, B. y Hoaglin, D. C. (1993). *How to Detect and Handle Outliers*. ASQC Quality Press.

Tukey, J. W. (1977). *Exploratory Data Analysis*. Addison-Wesley.

WineEnthusiast. Conjunto de datos winemag-data-130k-v2, provisto con el enunciado de la actividad.

Anexo. Estructura del script

El código se entrega en el archivo `script.py`, organizado en seis secciones que se corresponden con las de este informe. Se ejecuta con «`python script.py`» y requiere `pandas`, `numpy`, `matplotlib`, `scipy` y `openpyxl`. La ejecución completa demora unos catorce segundos y genera las ocho figuras en el directorio `graficos/`.

Tabla 10. Correspondencia entre las secciones del script y las de este informe.

Sección	Funciones principales
1. Carga de datos	<code>cargar_datos</code> , <code>_reconstruir_lineas</code> , <code>_reparar_codificacion</code>
2. Perfilado y depuración	<code>perfil_columnas</code> , <code>quitar_duplicados</code>
3. Visualización	<code>grafico_puntajes</code> , <code>grafico_precios</code> , <code>grafico_categoricas</code> , <code>grafico_precio_vs_puntaje</code> , <code>grafico_puntaje_por_pais</code>
4. Datos faltantes	<code>diagnostico_faltantes</code> , <code>validar_imputacion_precio</code> , <code>imputar_precio</code> , <code>tratar_faltantes</code> , <code>grafico_faltantes</code>
5. Datos atípicos	<code>detectar_atipicos</code> , <code>atipicos_contextuales</code> , <code>impacto_atipicos</code> , <code>grafico_atipicos</code>
6. Análisis comparativo	<code>extraer_anio</code> , <code>analisis_temporal</code> , <code>efecto_catador</code> , <code>mejor_relacion_calidad_precio</code> , <code>grafico_comparativo</code>

La función de carga incorpora aserciones que verifican la forma del conjunto y el tipo de las variables numéricas, de modo que el script falle de manera visible si el archivo de origen cambia, en lugar de continuar sobre datos distintos de los analizados.