

Enunciado de la actividad

El vino es una de las bebidas más antiguas y apreciadas del mundo, y su evaluación y clasificación ha sido una actividad de gran relevancia para enólogos, *sommeliers* y aficionados del vino por siglos. La habilidad de identificar el tipo de vino a partir de una descripción detallada es una capacidad avanzada que pocos dominan, siendo los *sommeliers* certificados los expertos más reconocidos en este ámbito. Este caso de estudio se centra en la utilización de la ciencia de datos para realizar un análisis exploratorio, limpieza y visualización de datos de un conjunto de reseñas de vinos.

La ciencia de datos ofrece herramientas y técnicas poderosas para extraer conocimiento y patrones significativos a partir de grandes volúmenes de datos. En este contexto, el análisis de datos de vinos puede proporcionar *insights* valiosos sobre las tendencias y características de los vinos, identificar patrones en las evaluaciones y descripciones, y ayudar a comprender mejor las preferencias y calificaciones de los consumidores.



Fuente: [Imagen sin título sobre vinos]. <https://bit.ly/3LFpSyh>

El set de datos utilizado en este estudio contiene reseñas de vinos obtenidas del sitio WineEnthusiast, proporcionando una base robusta para llevar a cabo el análisis exploratorio. A través de técnicas de limpieza y visualización de datos, se busca descubrir información relevante que podría ser útil para *sommeliers*, enólogos, comerciantes de vino y aficionados. El objetivo de este estudio es realizar un análisis exhaustivo de los datos disponibles para obtener una comprensión más profunda de las características y calificaciones de los vinos.

Contexto

El mundo del vino es complejo y fascinante, con una vasta cantidad de variedades, regiones de cultivo y métodos de producción. Cada vino tiene características únicas que pueden ser descritas a través de notas de cata, que incluyen aromas, sabores y otras sensaciones percibidas durante la degustación. Los *sommeliers*, mediante un riguroso entrenamiento, aprenden a identificar y describir estas características con gran precisión, lo cual les permite clasificar los vinos y, en muchos casos, identificar su variedad, origen y hasta el año de cosecha.

La industria del vino ha visto un crecimiento constante en la demanda de vinos de alta calidad, lo que ha llevado a una mayor competencia entre bodegas y regiones vinícolas. Las reseñas y puntuaciones de vinos por expertos juegan un papel crucial en la decisión de compra de los consumidores, influenciando sus preferencias y comportamientos. En este contexto, la capacidad de analizar y entender estas reseñas se convierte en una herramienta poderosa para bodegas y comerciantes de vino.

El análisis de descripciones de vinos puede revelar patrones interesantes sobre cómo diferentes variedades de uvas son percibidas por los consumidores y críticos. Por ejemplo, se pueden identificar descriptores comunes utilizados para ciertas variedades de uva, o descubrir cómo las características del vino varían entre diferentes regiones geográficas. Además, las puntuaciones y precios pueden ser analizados para entender mejor la relación entre la calidad percibida y el costo del vino.

La ciencia de datos proporciona técnicas avanzadas para analizar datos textuales, como el procesamiento de lenguaje natural (NLP). Estas técnicas permiten descomponer y analizar el texto de las descripciones de vinos para extraer características clave y patrones que pueden ser difíciles de detectar a simple vista. La limpieza de datos es otro aspecto crucial, ya que asegura que los datos sean consistentes y precisos, eliminando duplicados y corrigiendo errores.

Además de la limpieza y el análisis exploratorio de los datos, la visualización de datos juega un papel fundamental en este estudio. Mediante el uso de gráficos y visualizaciones interactivas, se pueden comunicar de manera efectiva los hallazgos y patrones descubiertos

en el análisis. Las visualizaciones permiten explorar los datos de manera más intuitiva, facilitando la identificación de tendencias y relaciones clave.

Este caso de estudio se centrará en el archivo `winemag-data-130k-v2.csv`, el cual contiene 130.000 reseñas de vinos con información detallada sobre el país de origen, la descripción, la designación del viñedo, los puntos otorgados, el precio, la provincia, las regiones específicas, el nombre del catador, su usuario de Twitter, el título de la reseña, la variedad de uva y la bodega productora. Este archivo proporciona una rica fuente de datos para llevar a cabo un análisis exploratorio exhaustivo.



Fuente: [Imagen sin título sobre viñedo]. <https://bit.ly/3WdkCqO>

El contexto de este estudio abarca la complejidad y diversidad del mundo del vino, la importancia de las reseñas y puntuaciones en la industria, y las poderosas herramientas que la ciencia de datos ofrece para analizar y visualizar estos datos. El objetivo es proporcionar una comprensión más profunda de las características y calificaciones de los vinos mediante un análisis detallado de las descripciones y otras variables presentes en el *dataset*.

Descripción de los datos

El set de datos contiene un archivo principal:

winemag-data-130k-v2.csv: Este archivo contiene 130.000 reseñas de vinos distribuidas en 10 columnas. Las columnas incluyen información detallada sobre el país de origen del vino, la descripción, la designación del viñedo, los puntos asignados por WineEnthusiast, el precio, la provincia, las regiones específicas dentro de la provincia, el nombre del catador, su usuario de Twitter, el título de la reseña, la variedad de uva y la bodega que produjo el vino.

El archivo principal de datos, winemag-data-130k-v2.csv, contiene información detallada que permite un análisis exhaustivo de los vinos y sus características. Cada columna del dataset proporciona una pieza clave de información:

- **country:** Esta columna especifica el país de origen del vino, lo cual es un factor importante, ya que las características del vino pueden variar significativamente según la región geográfica.
- **description:** La columna de descripción es la más relevante para este estudio, ya que se utilizará para realizar un análisis textual detallado. Las descripciones incluyen notas de cata detalladas que un *sommelier* utilizaría para evaluar el vino.
- **designation:** Indica el viñedo específico dentro de la bodega, proporcionando un nivel adicional de detalle sobre el origen del vino.
- **points:** La puntuación refleja la calidad percibida del vino según WineEnthusiast, en una escala de 1 a 100. Solo se publican reseñas de vinos con una puntuación de 80 o más.
- **price:** El precio de una botella de vino, que puede ser un indicador de la calidad percibida y la accesibilidad del vino.
- **province:** Especifica la provincia o estado de origen, que, junto con la columna de país, proporciona información geográfica detallada.
- **region_1 y region_2:** Estas columnas proporcionan información sobre áreas vinícolas específicas, lo cual puede ser crucial para identificar las características particulares de los vinos de esas regiones.
- **taster_name y taster_twitter_handle:** Proporcionan información sobre el catador que realizó la reseña, lo cual puede ser útil para análisis adicionales relacionados con la consistencia y estilo de las reseñas.
- **title:** El título de la reseña, que a menudo incluye el año de la cosecha, proporcionando un contexto temporal.
- **variety:** La variedad de uva es una etiqueta clave para este estudio, ya que se analizarán las descripciones para entender cómo se describen diferentes variedades.
- **winery:** La bodega que produjo el vino, que puede ser útil para identificar patrones específicos relacionados con productores.

En resumen, este *dataset* ofrece una rica fuente de datos textuales y numéricos que pueden ser explotados para realizar un análisis exploratorio exhaustivo en el ámbito del análisis de vinos. La combinación de técnicas de limpieza, exploración y visualización de datos permitirá abordar el desafío de extraer información valiosa y patrones significativos a partir de las descripciones textuales de los vinos, proporcionando *insights* útiles para una variedad de aplicaciones en la industria del vino.

Set de datos

A continuación, se adjunta el archivo que contiene el set de datos utilizado en este caso de estudio. El archivo, denominado **winemag-data-130k-v2.csv**, incluye 130,000 reseñas de vinos con información detallada sobre el país de origen, descripciones, puntuaciones, precios, variedades de uva y más. Este conjunto de datos será la base para el análisis exploratorio, limpieza y visualización de datos descritos anteriormente.